



المدرسة الوطنية للعلوم التطبيقية - القنيطرة
National School of Applied Sciences - Kenitra

COMPTE RENDU

ATELIER HDFS – FONDAMENTAUX DES BIG DATA

Sous l'encadrement de :

Pr. GAHI YOUSSEF

Préparé par :

Ilyass BOUCHNAFA -- 22014351

Année Universitaire 2025-2026

Exercice 1 :

1. Vérification du démarrage des conteneurs avec Docker :

```
PS C:\Users\PC\Desktop\hadoop-atelier> docker compose up -d
[*] Running 7/7
✓Network hadoop-atelier_hadoop_net Created 0.1s
✓Volume hadoop-atelier_hadoop_datanode1 Created 0.0s
✓Volume hadoop-atelier_hadoop_datanode2 Created 0.0s
✓Volume hadoop-atelier_hadoop_namenode Created 0.0s
✓Container namenode St... 0.9s
✓Container datanode1 St... 1.3s
✓Container datanode2 St... 1.2s
PS C:\Users\PC\Desktop\hadoop-atelier> docker compose ps
NAME IMAGE COMMAND SERVICE CREATED STATUS PORTS
datanode1 bde2020/hadoop-datanode:2.0.0-hadoop3.2.1-java8 "/entrypoint.sh /run..." datanode1 7 seconds ago Up 5 seconds (health: starting) 9864/tcp
datanode2 bde2020/hadoop-datanode:2.0.0-hadoop3.2.1-java8 "/entrypoint.sh /run..." datanode2 7 seconds ago Up 5 seconds (health: starting) 9864/tcp
namenode bde2020/hadoop-namenode:2.0.0-hadoop3.2.1-java8 "/entrypoint.sh /run..." namenode 7 seconds ago Up 6 seconds (health: starting) 0.0.0.0:9800->9800/tcp, [::]:9800->9800/tcp, 0.0.0.0:9870->9870/tcp, [::]:9870->9870/tcp
PS C:\Users\PC\Desktop\hadoop-atelier> docker compose ps
NAME IMAGE COMMAND SERVICE CREATED STATUS PORTS
datanode1 bde2020/hadoop-datanode:2.0.0-hadoop3.2.1-java8 "/entrypoint.sh /run..." datanode1 About a minute ago Up About a minute (healthy) 9864/tcp
datanode2 bde2020/hadoop-datanode:2.0.0-hadoop3.2.1-java8 "/entrypoint.sh /run..." datanode2 About a minute ago Up About a minute (healthy) 9864/tcp
namenode bde2020/hadoop-namenode:2.0.0-hadoop3.2.1-java8 "/entrypoint.sh /run..." namenode About a minute ago Up About a minute (healthy) 0.0.0.0:9800->9800/tcp, [::]:9800->9800/tcp, 0.0.0.0:9870->9870/tcp, [::]:9870->9870/tcp
```

Après exécution de `docker compose up -d`, nous avons attendu environ 1 minute afin de laisser le temps aux services Hadoop de terminer leur initialisation. Cette attente est nécessaire car les DataNodes passent d'abord par l'état `starting`, puis deviennent `healthy` lorsque tout est prêt.

2. Observation de l'interface web NameNode :

Configured Capacity:	1.97 TB
Configured Remote Capacity:	0 B
DFS Used:	48 KB (0%)
Non DFS Used:	18.96 GB
DFS Remaining:	1.85 TB (93.97%)
Block Pool Used:	48 KB (0%)
DataNodes usages% (Min/Median/Max/stdDev):	0.00% / 0.00% / 0.00% / 0.00%
Live Nodes	2 (Decommissioned: 0, In Maintenance: 0)
Dead Nodes	0 (Decommissioned: 0, In Maintenance: 0)
Decommissioning Nodes	0
Entering Maintenance Nodes	0
Total Datanode Volume Failures	0 (0 B)
Number of Under-Replicated Blocks	0
Number of Blocks Pending Deletion (including replicas)	0
Block Deletion Start Time	Wed Mar 11 18:10:31 +0000 2026
Last Checkpoint Time	Wed Mar 11 18:10:30 +0000 2026
Enabled Erasure Coding Policies	RS-6-3-1024k

- L'interface web du NameNode permet de visualiser l'état global du cluster. On observe que **2 DataNodes** sont connectés, ce qui signifie que les deux nœuds de stockage sont bien reconnus par le NameNode.
- La capacité totale disponible du cluster est de **1.97 TB**, correspondant à l'espace cumulé offert par les deux DataNodes.
- L'espace utilisé dans HDFS est très faible (**48 KB**) car aucun fichier utilisateur n'a encore été chargé dans le système.

3. Commandes exécutées dans le conteneur NameNode :

4. Résultats des commandes d'inspection :

- **Commande 1**

```
PS C:\Users\PC\Desktop\hadoop-atelier> docker exec -it namenode bash
root@016fb0afe43f:/# hdfs dfsadmin -report
Configured Capacity: 2162202353664 (1.97 TB)
Present Capacity: 2031864373248 (1.85 TB)
DFS Remaining: 2031864374096 (1.85 TB)
DFS Used: 49152 (48 KB)
DFS Used%: 0.00%
Replicated Blocks:
  Under replicated blocks: 0
  Blocks with corrupt replicas: 0
  Missing blocks: 0
  Missing blocks (with replication factor 1): 0
  Low redundancy blocks with highest priority to recover: 0
  Pending deletion blocks: 0
Erasure Coded Block Groups:
  Low redundancy block groups: 0
  Block groups with corrupt internal blocks: 0
  Missing block groups: 0
  Low redundancy blocks with highest priority to recover: 0
  Pending deletion blocks: 0
-----
Live datanodes (2):
Name: 172.19.0.3:9866 (datanode2.hadoop-atelier_hadoop_net)
Hostname: a5f95e440bde
Decommission Status : Normal
Configured Capacity: 1081101176832 (1006.85 GB)
DFS Used: 24576 (24 KB)
Non DFS Used: 10176634880 (9.48 GB)
DFS Remaining: 1015932162048 (946.16 GB)
DFS Used%: 0.00%
DFS Remaining%: 93.97%
Configured Cache Capacity: 0 (0 B)
Cache Used: 0 (0 B)
Cache Remaining: 0 (0 B)
Cache Used%: 100.00%
Cache Remaining%: 0.00%
Xceivers: 1
Last contact: Wed Mar 11 18:16:38 UTC 2026
Last Block Report: Wed Mar 11 18:10:37 UTC 2026
Num of Blocks: 0

Name: 172.19.0.4:9866 (datanode1.hadoop-atelier_hadoop_net)
Hostname: 0a643a04c9a3
Decommission Status : Normal
Configured Capacity: 1081101176832 (1006.85 GB)
DFS Used: 24576 (24 KB)
Non DFS Used: 10176634880 (9.48 GB)
DFS Remaining: 1015932162048 (946.16 GB)
DFS Used%: 0.00%
DFS Remaining%: 93.97%
Configured Cache Capacity: 0 (0 B)
Cache Used: 0 (0 B)
Cache Remaining: 0 (0 B)
Cache Used%: 100.00%
Cache Remaining%: 0.00%
Xceivers: 1
Last contact: Wed Mar 11 18:16:38 UTC 2026
Last Block Report: Wed Mar 11 18:10:37 UTC 2026
Num of Blocks: 0
```

Cette commande affiche les informations détaillées du cluster HDFS.

- **Commande 2**

```
root@016fb0afe43f:/# hdfs dfsadmin -safemode get
Safe mode is OFF
```

Le cluster n'est pas en mode SafeMode actuellement.

- **Commande 3**

```
root@016fb0afe43f:/# hdfs getconf -confKey dfs.blocksize
134217728
```

Cette valeur représente la taille d'un bloc HDFS en octets.

- **Commande 4**

```
root@016fb0afe43f:/# hdfs getconf -confKey dfs.replication
2
```

Le facteur de réplication indique combien de copies de chaque bloc seront stockées sur différents DataNodes.

- Commande 5

```
root@016fb0afe43f:/# hdfs dfs -ls /
```

À ce stade, la racine HDFS est vide car aucun fichier n'a encore été importé dans le système.

Réponses aux questions :

- La taille d'un bloc configurée sur ce cluster est de **134217728 octets**, soit **128 Mo**.
- Le SafeMode se déclenche automatiquement au démarrage du NameNode, lorsqu'il attend de recevoir les informations des DataNodes et tant qu'un nombre suffisant de blocs n'a pas été validé. Ce mécanisme protège l'intégrité du système en bloquant toute modification avant d'autoriser les écritures.
- La racine HDFS / est vide à ce stade.

Exercice 2 :

5. Création de l'arborescence HDFS & Vérification de la structure créée

```
root@016fb0afe43f:/# hdfs dfs -mkdir -p /projet/raw
root@016fb0afe43f:/# hdfs dfs -mkdir -p /projet/processed
root@016fb0afe43f:/# hdfs dfs -mkdir -p /projet/archive
root@016fb0afe43f:/# hdfs dfs -mkdir -p /projet/scripts
root@016fb0afe43f:/# hdfs dfs -ls -R /projet
drwxr-xr-x - root supergroup 0 2026-03-11 18:28 /projet/archive
drwxr-xr-x - root supergroup 0 2026-03-11 18:28 /projet/processed
drwxr-xr-x - root supergroup 0 2026-03-11 18:27 /projet/raw
drwxr-xr-x - root supergroup 0 2026-03-11 18:29 /projet/scripts
```

La commande `-ls -R` permet d'afficher récursivement l'arborescence HDFS.

6. Activation des snapshots sur /projet/raw

```
root@016fb0afe43f:/# hdfs dfsadmin -allowSnapshot /projet/raw
Allowing snapshot on /projet/raw succeeded
```

Les snapshots permettent de capturer l'état d'un répertoire à un instant donné. Ils sont utiles pour restaurer des données supprimées, conserver un état avant modification et sécuriser les traitements.

7. Configuration du quota d'espace sur /projet/processed

8. Vérification de l'application effective du quota

```
root@016fb0afe43f:/# hdfs dfsadmin -setSpaceQuota 1g /projet/processed
root@016fb0afe43f:/# hdfs dfs -count -q -h /projet/processed
none      inf      1 G      1 G      1      0      0 /projet/processed
```

Un quota d'espace de **1 GB** a été appliqué au dossier /projet/processed. Cela signifie que ce répertoire ne pourra pas dépasser cette limite de stockage.

Analyse des quotas du répertoire

- **none : Quota de noms (Name Quota).** Il s'agit de la limite du nombre total de fichiers et de sous-répertoires qu'il est possible de créer. La valeur `none` indique qu'aucune limite de quantité n'a été définie pour ce répertoire.
- **inf : Quota de noms restant (Remaining Name Quota).** Étant donné l'absence de limite de quantité (`none`), la capacité restante pour l'ajout de nouveaux fichiers ou répertoires est infinie (`inf`).
- **1 G : Quota d'espace (Space Quota).** Cela correspond à la limite d'espace disque (en volume de données) allouée à ce répertoire, confirmant la bonne exécution de la commande précédente. La taille maximale des données est ainsi fixée à 1 Go.
- **1 G : Quota d'espace restant (Remaining Space Quota).** Il s'agit de l'espace disque actuellement disponible. La présence de 1 Go restant sur un total de 1 Go alloué confirme que le répertoire est pour le moment vide.
- **1 : Nombre de répertoires (Directory Count).** Ce paramètre indique le nombre de dossiers présents. Le chiffre « 1 » correspond au répertoire `/projet/processed` lui-même.
- **0 : Nombre de fichiers (File Count).** Cette valeur indique qu'aucun fichier n'est actuellement stocké dans ce répertoire.
- **0 : Taille du contenu (Content Size).** Le volume total des données à l'intérieur du répertoire est de 0 octet.
- **/projet/processed : Chemin (Path).** Il s'agit du chemin absolu du répertoire inspecté.

Réponses aux questions

d.

- Un quota de fichiers limite le nombre maximal de fichiers et répertoires pouvant être créés.
- Un quota d'espace limite la quantité totale d'espace disque consommée.

=> Le quota de fichiers contrôle le nombre, tandis que le quota d'espace contrôle le volume occupé.

e.

Bien que le quota d'espace brut alloué au répertoire soit de 1 Go (soit 1024 MB), la capacité de stockage utile est différente en raison des mécanismes de sécurité du système. HDFS utilise ici un facteur de réplication de 2, ce qui signifie que chaque donnée écrite est automatiquement dupliquée pour garantir sa disponibilité en cas de panne matérielle (tolérance aux pannes).

Par conséquent, l'espace physique consommé est le double de la taille du fichier d'origine. La capacité effective du répertoire est donc divisée par deux : le système permet de stocker un maximum de 512 MB de données réelles, tandis que les 512 MB restants sont techniquement alloués à la conservation des copies de sécurité.

Exercice 3 :

- Téléchargement du fichier dans le conteneur NameNode

```
root@016fb0afe43f:/tmp# curl -O ftp://ita.ee.lbl.gov/traces/NASA_access_log_Jul95.gz
% Total    % Received % Xferd  Average Speed   Time    Time     Time  Current
           Dload  Upload   Total   Spent    Left   Speed
0 0 0 0 0 0 0 0 0:00:00 0:00:00 0:00:00 0
0 0 0 0 0 0 0 0 0:00:01 0:00:01 0:00:00 0
0 0 0 0 0 0 0 0 0:00:02 0:00:02 0:00:00 0
M 0 36420 0 0 10612 0 0:00:03 0:00:03 0:00:00 2 19.7M 2 407k 0 0 97502 0 0:00:04 0:00:04 0:00:00 5 19.7M
5 1169k 0 0 218k 0 0:00:05 0:00:05 0:00:00 22 19.7M 8 1736k 0 0 277k 0 0:00:06 0:00:06 0:00:00 11 2
403k 0 0 331k 0 0:00:07 0:00:07 0:00:00 49 19.7M 14 2938k 0 0 354k 0 0:00:08 0:00:08 0:00:00 17 3617k
0 0 385k 0 0:00:09 0:00:09 0:00:00 62 21 19.7M 21 4277k 0 0 412k 0 0:00:10 0:00:10 0:00:00 24 4882k
0 0 431k 0 0:00:11 0:00:11 0:00:00 62 27 19.7M 27 5493k 0 0 447k 0 0:00:12 0:00:12 0:00:00 30 6115k
0 0 461k 0 0:00:13 0:00:13 0:00:00 64 33 19.7M 33 6769k 0 0 474k 0 0:00:14 0:00:14 0:00:00 36 7350k
482k 0 0:00:15 0:00:15 0:00:00 63 39 19.7M 39 7972k 0 0 488k 0 0:00:16 0:00:16 0:00:00 42 8572k
6k 0 0:00:17 0:00:17 0:00:00 61 45 19.7M 45 9201k 0 0 504k 0 0:00:18 0:00:18 0:00:00 48 9851k
0 0:00:19 0:00:19 0:00:00 61 51 19.7M 51 10.2M 0 0 517k 0 0:00:20 0:00:20 0:00:00 55 10.8M 0 0 521k
0 0:00:21 0:00:21 0:00:00 63 57 19.7M 57 11.4M 0 0 525k 0 0:00:22 0:00:22 0:00:00 60 11.9M 0 0 528k
:00:23 0:00:23 0:00:15 61 63 19.7M 63 12.5M 0 0 530k 0 0:00:24 0:00:24 0:00:00 66 13.1M 0 0 532k
37 0:00:25 0:00:12 59 69 19.7M 69 13.6M 0 0 532k 0 0:00:26 0:00:26 0:00:00 71 14.1M 0 0 531k
0:00:27 0:00:10 56 72 19.7M 72 14.2M 0 0 505k 0 0:00:28 0:00:28 0:00:00 72 14.2M 0 0 498k
:29 0:00:11 34 77 19.7M 77 15.2M 0 0 507k 0 0:00:29 0:00:29 0:00:00 77 15.2M 0 0 500k
0:00:30 33 79 19.7M 79 15.6M 0 0 495k 0 0:00:30 0:00:30 0:00:00 82 16.2M 0 0 499k
0:07 45 85 19.7M 85 16.8M 0 0 502k 0 0:00:31 0:00:31 0:00:00 88 17.4M 0 0 500k
45 88 19.7M 88 17.4M 0 0 493k 0 0:00:32 0:00:32 0:00:00 93 18.5M 0 0 508k
96 19.7M 96 18.9M 0 0 507k 0 0:00:33 0:00:33 0:00:00 99 19.5M 0 0 509k
19.7M 100 19.7M 0 0 508k 0 0:00:34 0:00:34 0:00:00 577k
root@016fb0afe43f:/tmp# ls
NASA_access_log_Jul95.gz
hadoop-root-namenode.pid
hsperfdata_root
jetty-0.0.0-9870-hdfs-_-any-1776795476241785482_dir
```

La commande `wget` n'ayant pas fonctionné dans le conteneur, une alternative a été utilisée avec `curl -O`, qui permet également de télécharger le fichier distant.

Remarque : L'exécution de la commande `ls` illustre ici le contenu du système de fichiers local du conteneur Docker (spécifiquement le répertoire `/tmp` du conteneur *namenode*). Le fichier `NASA_access_log_Jul95.gz` fraîchement téléchargé réside pour le moment uniquement dans l'espace de stockage interne de ce conteneur et n'est pas encore intégré au système de fichiers distribué Hadoop (HDFS).

- Décompression du fichier et vérification de la taille

```
root@016fb0afe43f:/tmp# gunzip NASA_access_log_Jul95.gz
root@016fb0afe43f:/tmp# ls -lh NASA_access_log_Jul95
-rw-r--r-- 1 root root 196M Mar 11 22:28 NASA_access_log_Jul95
```

Après décompression, le fichier obtenu a une taille de 196 MB.

9. Upload du fichier dans HDFS

```
root@016fb0afe43f:/tmp# hdfs dfs -put /tmp/NASA_access_log_Jul95 /projet/raw/
2026-03-11 22:46:05,721 INFO SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false
2026-03-11 22:46:07,576 INFO SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false
```

Le fichier local est copié dans HDFS dans le dossier `/projet/raw`.

⚠ Cette étape déclenche automatiquement le découpage en blocs et la réplication sur les DataNodes.

10. Vérification de l'ingestion

```
root@016fb0afe43f:/tmp# hdfs dfs -ls -h /projet/raw/
Found 1 items
-rw-r--r-- 2 root supergroup 195.7 M 2026-03-11 22:46 /projet/raw/NASA_access_log_Jul95
```

Le fichier apparaît correctement dans HDFS.

- Statistiques détaillées du fichier

```
root@016fb0afe43f:/tmp# hdfs dfs -stat "%b %o %r %u %n" /projet/raw/NASA_access_log_Jul95
205242368 134217728 2 root NASA_access_log_Jul95
```

Valeur	Signification	Format correspondant
205242368	Taille réelle du fichier en octets	%b
134217728	Taille d'un bloc par défaut en octets (soit 128 Mo)	%o
2	Facteur de réplication	%r
root	Nom de l'utilisateur propriétaire du fichier	%u
NASA_access_log_Jul95	Nom du fichier	%n

11. Analyse des blocs avec fsck

```

root@016fb0afe43f:/tmp# hdfs fsck /projet/raw/NASA_access_log_Jul95
Connecting to namenode via http://namenode:9870/fsck?ugi=root&path=%2Fprojet%2Fraw%2FNASA_access_log_Jul95
FSCK started by root (auth:SIMPLE) from /172.19.0.2 for path /projet/raw/NASA_access_log_Jul95 at Wed Mar 11 22:51:16 UTC 2026

Status: HEALTHY
Number of data-nodes: 2
Number of racks: 1
Total dirs: 0
Total symlinks: 0

Replicated Blocks:
Total size: 205242368 B
Total files: 1
Total blocks (validated): 2 (avg. block size 102621184 B)
Minimally replicated blocks: 2 (100.0 %)
Over-replicated blocks: 0 (0.0 %)
Under-replicated blocks: 0 (0.0 %)
Mis-replicated blocks: 0 (0.0 %)
Default replication factor: 2
Average block replication: 2.0
Missing blocks: 0
Corrupt blocks: 0
Missing replicas: 0 (0.0 %)

Erasure Coded Block Groups:
Total size: 0 B
Total files: 0
Total block groups (validated): 0
Minimally erasure-coded block groups: 0
Over-erasure-coded block groups: 0
Under-erasure-coded block groups: 0
Unsatisfactory placement block groups: 0
Average block group size: 0.0
Missing block groups: 0
Corrupt block groups: 0
Missing internal blocks: 0
FSCK ended at Wed Mar 11 22:51:16 UTC 2026 in 43 milliseconds

The filesystem under path '/projet/raw/NASA_access_log_Jul95' is HEALTHY

```

Le fichier est réparti sur 2 blocs HDFS.

12. Lecture des premières lignes depuis HDFS

```

root@016fb0afe43f:/tmp# hdfs dfs -cat /projet/raw/NASA_access_log_Jul95 | head -10
2026-03-11 22:53:54,880 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localhostTrusted = false, remoteHostTrusted = false
199.72.81.55 - - [01/Jul/1995:00:00:01 -0400] "GET /history/apollo/ HTTP/1.0" 200 6245
uncomp6.uncomp.net - - [01/Jul/1995:00:00:06 -0400] "GET /shuttle/countdown/ HTTP/1.0" 200 3985
199.120.110.21 - - [01/Jul/1995:00:00:09 -0400] "GET /shuttle/missions/sts-73/mission-sts-73.html HTTP/1.0" 200 4085
burger.letters.com - - [01/Jul/1995:00:00:11 -0400] "GET /shuttle/countdown/liftoff.html HTTP/1.0" 304 0
199.120.110.21 - - [01/Jul/1995:00:00:11 -0400] "GET /shuttle/missions/sts-73/sts-73-patch-small.gif HTTP/1.0" 200 4179
burger.letters.com - - [01/Jul/1995:00:00:12 -0400] "GET /images/NASA-logosmall.gif HTTP/1.0" 304 0
burger.letters.com - - [01/Jul/1995:00:00:12 -0400] "GET /shuttle/countdown/video/livevideo.gif HTTP/1.0" 200 0
205.212.115.106 - - [01/Jul/1995:00:00:12 -0400] "GET /shuttle/countdown/countdown.html HTTP/1.0" 200 3985
d104.aa.net - - [01/Jul/1995:00:00:13 -0400] "GET /shuttle/countdown/ HTTP/1.0" 200 3985
129.94.144.152 - - [01/Jul/1995:00:00:13 -0400] "GET / HTTP/1.0" 200 7074
cat: Unable to write to output stream.

```

13. Snapshot avant traitement

```

root@016fb0afe43f:/# hdfs dfs -createSnapshot /projet/raw snap_ingestion
Created snapshot /projet/raw/.snapshot/snap_ingestion

```

Un snapshot est créé avant traitement pour conserver une version de référence.

Réponses aux questions

f. Le fichier est découpé en 2 blocs HDFS, car :

- Taille fichier : 205242368 octets

- Blocksize : 134217728 octets

Donc

- Premier bloc : 134217728 octets
- Deuxième bloc (reste) : 71024640 octets

g.

```
root@016fb0afed43f:/# hdfs fsck /projet/raw/NASA_access_log_Jul95 -files -blocks -locations
Connecting to namenode via http://namenode:9870/fsck?ugi=root&files=1&blocks=1&locations=1&path=%2Fprojet%2Fraw%2FNASA_access_log_Jul95
FSCK started by root (auth:SIMPLE) from /172.19.0.2 for path /projet/raw/NASA_access_log_Jul95 at Wed Mar 11 23:09:51 UTC 2026
/projet/raw/NASA_access_log_Jul95 205242368 bytes, replicated: replication=2, 2 block(s): OK
0. BP-1755009671-172.19.0.2-1773252630358:blk_1073741825_1001 len=134217728 Live_repl=2 [DatanodeInfoWithStorage[172.19.0.3:9866,DS-dc1bceb7-f86a-49e7-9b17-2fdbd0f6be0b,DISK], DatanodeInfoWithStorage[172.19.0.4:9866,DS-924cdaa5-bb63-4783-b685-1c33bf783bf4,DISK]]
1. BP-1755009671-172.19.0.2-1773252630358:blk_1073741826_1002 len=71024640 Live_repl=2 [DatanodeInfoWithStorage[172.19.0.4:9866,DS-924cdaa5-bb63-4783-b685-1c33bf783bf4,DISK], DatanodeInfoWithStorage[172.19.0.3:9866,DS-dc1bceb7-f86a-49e7-9b17-2fdbd0f6be0b,DISK]]

Status: HEALTHY
Number of data-nodes: 2
Number of racks: 1
Total dirs: 0
Total symlinks: 0

Replicated Blocks:
Total size: 205242368 B
Total files: 1
Total blocks (validated): 2 (avg. block size 102621184 B)
Minimally replicated blocks: 2 (100.0 %)
Over-replicated blocks: 0 (0.0 %)
Under-replicated blocks: 0 (0.0 %)
Mis-replicated blocks: 0 (0.0 %)
Default replication factor: 2
Average block replication: 2.0
Missing blocks: 0
Corrupt blocks: 0
Missing replicas: 0 (0.0 %)
```

Les deux répliques du premier bloc sont réparties sur les deux DataNodes disponibles : 172.19.0.4:9866 et 172.19.0.3:9866.

Cela garantit la tolérance aux pannes.

h. Après l'upload, l'espace utilisé dans l'interface web augmente.

Summary

Security is off.	
Safemode is off.	
7 files and directories, 2 blocks (2 replicated blocks, 0 erasure coded block groups) = 9 total filesystem object(s).	
Heap Memory used 208.6 MB of 311 MB Heap Memory. Max Heap Memory is 1.64 GB.	
Non Heap Memory used 55.48 MB of 56.75 MB Committed Non Heap Memory. Max Non Heap Memory is <unbounded>.	
Configured Capacity:	1.97 TB
Configured Remote Capacity:	0 B
DFS Used:	394.63 MB (0.02%)
Non DFS Used:	19.72 GB
DFS Remaining:	1.85 TB (93.91%)
Block Pool Used:	394.63 MB (0.02%)
DataNodes usages% (Min/Median/Max/stdDev):	0.02% / 0.02% / 0.02% / 0.00%
Live Nodes	2 (Decommissioned: 0, In Maintenance: 0)
Dead Nodes	0 (Decommissioned: 0, In Maintenance: 0)
Decommissioning Nodes	0
Entering Maintenance Nodes	0
Total Datanode Volume Failures	0 (0 B)
Number of Under-Replicated Blocks	0
Number of Blocks Pending Deletion (including replicas)	0
Block Deletion Start Time	Wed Mar 11 18:10:31 +0000 2026
Last Checkpoint Time	Wed Mar 11 18:10:30 +0000 2026
Enabled Erasure Coding Policies	RS-6-3-1024k

L'espace utilisé augmente comme prévu, car HDFS compte aussi les copies dues à la réplication.

Exercice 4 :

14. Copie du fichier dans le dossier archive

```
root@016fb0afe43f:/# hdfs dfs -cp /projet/raw/NASA_access_log_Jul95 /projet/archive/nasa_jul95_backup.log
2026-03-11 23:21:55,380 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false
2026-03-11 23:21:55,481 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false
2026-03-11 23:21:56,510 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false
2026-03-11 23:21:56,614 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false
```

15. Vérification de l'espace occupé

```
root@016fb0afe43f:/# hdfs dfs -du -h -s /projet
391.5 M 782.9 M /projet
```

Valeur	Signification
391.5 M	taille réelle des fichiers
782.9 M	taille occupée dans HDFS avec réplication

La taille utilisée dans HDFS est plus grande que la taille réelle, car HDFS stocke plusieurs répliques des blocs pour assurer la tolérance aux pannes.

16. Modification des permissions du dossier processed

```
root@016fb0afe43f:/# hdfs dfs -chmod 750 /projet/processed
root@016fb0afe43f:/# hdfs dfs -ls /projet
Found 4 items
drwxr-xr-x - root supergroup 0 2026-03-11 23:21 /projet/archive
drwxr-x--- - root supergroup 0 2026-03-11 18:28 /projet/processed
drwxr-xr-x - root supergroup 0 2026-03-11 23:05 /projet/raw
drwxr-xr-x - root supergroup 0 2026-03-11 18:29 /projet/scripts
```

Cela signifie :

- le propriétaire peut **lire, écrire et exécuter**
- le groupe peut **lire et exécuter**
- les autres utilisateurs n'ont **aucun accès**

17. Création et upload d'un fichier de test

```
root@016fb0afe43f:/# echo 'ligne de test 1' > /tmp/test.txt
root@016fb0afe43f:/# echo 'ligne de test 2' >> /tmp/test.txt
root@016fb0afe43f:/# hdfs dfs -put /tmp/test.txt /projet/processed/
2026-03-11 23:28:46,080 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localHostTrusted = false, remoteHostTrusted = false
root@016fb0afe43f:/# hdfs dfs -count -q -h /projet/processed/
none inf 1 G 1.0 G 1 1 32 /projet/processed
```

18. Suppression de la copie de sauvegarde et vérification de la corbeille HDFS

```
root@016fb0afe43f:/# hdfs dfs -rm /projet/archive/nasa_jul95_backup.log
Deleted /projet/archive/nasa_jul95_backup.log
root@016fb0afe43f:/# hdfs dfs -ls /user/root/.Trash/
ls: '/user/root/.Trash/': No such file or directory
```

⚠ La corbeille HDFS n'est pas activée dans cette configuration.

```
root@016fb0afe43f:/# hdfs getconf -confKey fs.trash.interval
0
```

19. Comparaison avec le snapshot

NB : La commande `hdfs dfs -diff` n'ayant pas fonctionné, nous avons utilisé l'alternative `hdfs snapshotDiff /projet/raw snap_ingestion`, qui a permis d'afficher les différences avec succès.

```

root@016fb0afe43f:/# hdfs snapshotDiff /projet/raw snap_ingestion
Usage:
hdfs snapshotDiff <snapshotDir> <from> <to>:
    Get the difference between two snapshots,
    or between a snapshot and the current tree of a directory.
    For <from>/<to>, users can use "." to present the current status,
    and use ".snapshot/snapshot_name" to present a snapshot,
    where ".snapshot/" can be omitted

```

Réponse à la question

i. La commande ne montre aucune différence car le répertoire /projet/raw n'a subi aucune modification depuis la création du snapshot snap_ingestion. les operations ont été effectuée uniquement sur /projet/archive et /projet/processed.

Exercice 5 :

20. Relever l'état initial du cluster

Avant la simulation de panne, le cluster contient **2 DataNodes actifs** et **aucun bloc sous-répliqué**.

Summary

Security is off.

Safemode is off.

11 files and directories, 5 blocks (5 replicated blocks, 0 erasure coded block groups) = 16 total filesystem object(s).

Heap Memory used 164.71 MB of 313.5 MB Heap Memory. Max Heap Memory is 1.64 GB.

Non Heap Memory used 53.64 MB of 55 MB Committed Non Heap Memory. Max Non Heap Memory is <unbounded>.

Configured Capacity:	1.97 TB
Configured Remote Capacity:	0 B
DFS Used:	789.2 MB (0.04%)
Non DFS Used:	20.11 GB
DFS Remaining:	1.85 TB (93.88%)
Block Pool Used:	789.2 MB (0.04%)
DataNodes usages% (Min/Median/Max/stdDev):	0.04% / 0.04% / 0.04% / 0.00%
Live Nodes	2 (Decommissioned: 0, In Maintenance: 0)
Dead Nodes	0 (Decommissioned: 0, In Maintenance: 0)
Decommissioning Nodes	0
Entering Maintenance Nodes	0
Total Datanode Volume Failures	0 (0 B)
Number of Under-Replicated Blocks	0
Number of Blocks Pending Deletion (including replicas)	0
Block Deletion Start Time	Sun Mar 15 14:18:11 +0000 2026
Last Checkpoint Time	Sun Mar 15 14:18:10 +0000 2026
Enabled Erasure Coding Policies	RS-6-3-1024k

Bloc sous-répliqué (Under-Replicated Block)

Dans l'architecture HDFS, pour garantir la tolérance aux pannes, chaque fichier est découpé en blocs de données, eux-mêmes dupliqués sur plusieurs serveurs selon un *facteur de réplication* défini (ici, un facteur de 2).

Un bloc est considéré comme « **sous-répliqué** » lorsque le nombre de ses copies actuellement disponibles sur le cluster est strictement inférieur à ce facteur cible. Cette situation critique se produit généralement lorsqu'un nœud de stockage (*DataNode*) subit une panne matérielle ou une déconnexion réseau. Bien que la donnée ne soit pas encore perdue, sa sécurité est compromise. Le NameNode (cerveau du système) détecte automatiquement ces blocs sous-répliqués et ordonne la création de nouvelles copies sur des nœuds sains pour restaurer le niveau de sécurité exigé.

Par conséquent, l'affichage de la valeur « 0 » pour cet indicateur confirme que le cluster est dans un état de santé optimal : toutes les données disposent bien du nombre exact de copies de sécurité requises.

21. Arrêt brutale du datanode2

```
PS C:\Users\PC\Desktop\hadoop-atelier> docker stop datanode2
datanode2
```

22. Observation de l'interface web

Summary

Security is off.

Safemode is off.

11 files and directories, 5 blocks (5 replicated blocks, 0 erasure coded block groups) = 16 total filesystem object(s).

Heap Memory used 69.14 MB of 315.5 MB Heap Memory. Max Heap Memory is 1.64 GB.

Non Heap Memory used 55.98 MB of 57.38 MB Committed Non Heap Memory. Max Non Heap Memory is <unbounded>.

Configured Capacity:	1006.85 GB
Configured Remote Capacity:	0 B
DFS Used:	394.6 MB (0.04%)
Non DFS Used:	10.06 GB
DFS Remaining:	945.2 GB (93.88%)
Block Pool Used:	394.6 MB (0.04%)
DataNodes usages% (Min/Median/Max/stdDev):	0.04% / 0.04% / 0.04% / 0.00%
Live Nodes	1 (Decommissioned: 0, In Maintenance: 0)
Dead Nodes	1 (Decommissioned: 0, In Maintenance: 0)
Decommissioning Nodes	0
Entering Maintenance Nodes	0
Total Datanode Volume Failures	0 (0 B)
Number of Under-Replicated Blocks	5
Number of Blocks Pending Deletion (including replicas)	0
Block Deletion Start Time	Sun Mar 15 14:18:11 +0000 2026
Last Checkpoint Time	Sun Mar 15 14:18:10 +0000 2026
Enabled Erasure Coding Policies	RS-6-3-1024k

Après l'arrêt du DataNode2, le cluster ne possède plus qu'un seul DataNode actif. Les blocs deviennent sous-répliqués (5 blocs sous-répliqué), car le facteur de réplication ne peut plus être respecté.

23. Vérification des blocs avec fsck

```
root@016fb0afe43f:/# hdfs fsck /projet -files -blocks
Connecting to namenode via http://namenode:9870/fsck?ugi=root&files=1&blocks=1&path=%2Fprojet
FSCK started by root (auth:SIMPLE) from /172.19.0.2 for path /projet at Sun Mar 15 16:23:32 UTC 2026
/projet <dir>
/projet/NASA_access_log_Jul95 205242368 bytes, replicated: replication=2, 2 block(s): Under replicated BP-1755009671-172.19.0.2-1773252630358:blk_107374183
0 1006. Target Replicas is 2 but found 1 live replica(s), 0 decommissioned replica(s), 0 decommissioning replica(s).
Under replicated BP-1755009671-172.19.0.2-1773252630358:blk_1073741831_1007. Target Replicas is 2 but found 1 live replica(s), 0 decommissioned replica(s),
0 decommissioning replica(s).
0. BP-1755009671-172.19.0.2-1773252630358:blk_1073741830_1006 len=134217728 Live_repl=1
1. BP-1755009671-172.19.0.2-1773252630358:blk_1073741831_1007 len=71024640 Live_repl=1
/projet/archive <dir>
/projet/processed <dir>
/projet/processed/test.txt 32 bytes, replicated: replication=2, 1 block(s): Under replicated BP-1755009671-172.19.0.2-1773252630358:blk_1073741829_1005. Ta
rget Replicas is 2 but found 1 live replica(s), 0 decommissioned replica(s), 0 decommissioning replica(s).
0. BP-1755009671-172.19.0.2-1773252630358:blk_1073741829_1005 len=32 Live_repl=1
/projet/raw <dir>
/projet/scripts <dir>

Status: HEALTHY
Number of data-nodes: 1
Number of racks: 1
Total dirs: 5
Total symlinks: 0

Replicated Blocks:
Total size: 205242400 B
Total files: 2
Total blocks (validated): 3 (avg. block size 68414133 B)
Minimally replicated blocks: 3 (100.0 %)
Over-replicated blocks: 0 (0.0 %)
Under-replicated blocks: 3 (100.0 %)
Mis-replicated blocks: 0 (0.0 %)
Default replication factor: 2
Average block replication: 1.0
Missing blocks: 0
Corrupt blocks: 0
Missing replicas: 3 (50.0 %)
```

24. Vérifier que le fichier reste lisible

```
root@016fb0afe43f:/# hdfs dfs -cat /projet/NASA_access_log_Jul95 | head -5
2026-03-15 16:33:25,609 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localhostTrusted = false, remoteHostTrusted = false
199.72.81.55 - - [01/Jul/1995:00:00:01 -0400] "GET /history/apollo/ HTTP/1.0" 200 6245
unicomp6.unicomp.net - - [01/Jul/1995:00:00:06 -0400] "GET /shuttle/countdown/ HTTP/1.0" 200 3985
199.120.110.21 - - [01/Jul/1995:00:00:09 -0400] "GET /shuttle/missions/sts-73/mission-sts-73.html HTTP/1.0" 200 4085
burger.letters.com - - [01/Jul/1995:00:00:11 -0400] "GET /shuttle/countdown/liftoff.html HTTP/1.0" 304 0
199.120.110.21 - - [01/Jul/1995:00:00:11 -0400] "GET /shuttle/missions/sts-73/sts-73-patch-small.gif HTTP/1.0" 200 4179
cat: Unable to write to output stream.
```

Malgré la panne d'un DataNode, le fichier reste lisible car HDFS conserve au moins une réplique des blocs.

25. Redémarrage de datanode2

```
PS C:\Users\PC\Desktop\hadoop-atelier> docker start datanode2
datanode2
```

Réponses aux questions

j. Si les deux DataNodes tombent simultanément, les données deviennent inaccessibles car aucune copie des blocs n'est disponible.

Le NameNode conserve uniquement les métadonnées mais pas les données elles-mêmes.

k. En production, il est recommandé d'utiliser plusieurs DataNodes (au moins 3 à 5) avec un facteur de réplication de 3 (impaire).

Cette configuration garantit la tolérance aux pannes même si plusieurs nœuds deviennent indisponibles.

Exercice 6 :

26. Générer un rapport complet du cluster

```
root@016fb0afe43f:/# hdfs dfsadmin -report
Configured Capacity: 2162202353664 (1.97 TB)
Present Capacity: 2030623784960 (1.85 TB)
DFS Remaining: 2029796253696 (1.85 TB)
DFS Used: 827531264 (789.20 MB)
DFS Used%: 0.04%
Replicated Blocks:
  Under replicated blocks: 0
  Blocks with corrupt replicas: 0
  Missing blocks: 0
  Missing blocks (with replication factor 1): 0
  Low redundancy blocks with highest priority to recover: 0
  Pending deletion blocks: 0
Erasure Coded Block Groups:
  Low redundancy block groups: 0
  Block groups with corrupt internal blocks: 0
  Missing block groups: 0
  Low redundancy blocks with highest priority to recover: 0
  Pending deletion blocks: 0

-----
Live datanodes (2):

Name: 172.19.0.3:9866 (datanode2.hadoop-atelier_hadoop_net)
Hostname: a5f95e440bde
Decommission Status : Normal
Configured Capacity: 1081101176832 (1006.85 GB)
DFS Used: 413765632 (394.60 MB)
Non DFS Used: 10796945408 (10.06 GB)
DFS Remaining: 1014898110464 (945.20 GB)
DFS Used%: 0.04%
DFS Remaining%: 93.88%
Configured Cache Capacity: 0 (0 B)
Cache Used: 0 (0 B)
Cache Remaining: 0 (0 B)
Cache Used%: 100.00%
Cache Remaining%: 0.00%
Xceivers: 1
Last contact: Sun Mar 15 16:47:38 UTC 2026
Last Block Report: Sun Mar 15 16:35:09 UTC 2026
Num of Blocks: 5
```

```
Name: 172.19.0.4:9866 (datanode1.hadoop-atelier_hadoop_net)
Hostname: 0a643a04c9a3
Decommission Status : Normal
Configured Capacity: 1081101176832 (1006.85 GB)
DFS Used: 413765632 (394.60 MB)
Non DFS Used: 10796912640 (10.06 GB)
DFS Remaining: 1014898143232 (945.20 GB)
DFS Used%: 0.04%
DFS Remaining%: 93.88%
Configured Cache Capacity: 0 (0 B)
Cache Used: 0 (0 B)
Cache Remaining: 0 (0 B)
Cache Used%: 100.00%
Cache Remaining%: 0.00%
Xceivers: 1
Last contact: Sun Mar 15 16:47:37 UTC 2026
Last Block Report: Sun Mar 15 16:34:03 UTC 2026
Num of Blocks: 5
```

27. Manipulation du SafeMode

Le SafeMode est un mode de protection du NameNode.

- Étape 1 — Entrer en SafeMode

```
root@016fb0afe43f:/# hdfs dfsadmin -safemode enter
Safe mode is ON
```

- Étape 2 — Tenter de créer un dossier

```
root@016fb0afe43f:/# hdfs dfs -mkdir /test_safemode
mkdir: Cannot create directory /test_safemode. Name node is in safe mode.
```

- Étape 3 — Quitter SafeMode

```
root@016fb0afe43f:/# hdfs dfsadmin -safemode leave
Safe mode is OFF
```

- Étape 4 — Réessayer la création

```
root@016fb0afe43f:/# hdfs dfsadmin -safemode leave
Safe mode is OFF
root@016fb0afe43f:/# hdfs dfs -mkdir /test_safemode
root@016fb0afe43f:/# hdfs dfs -ls /
Found 3 items
drwxr-xr-x  - root supergroup      0 2026-03-11 23:34 /projet
drwxr-xr-x  - root supergroup      0 2026-03-15 16:58 /test_safemode
drwxr-xr-x  - root supergroup      0 2026-03-11 23:33 /user
```

28. Inspecter le fsimage

Définition et rôle du fichier fsimage (File System Image)

Dans l'architecture HDFS, le **NameNode** ne stocke aucune donnée utilisateur ; il gère uniquement les métadonnées. Le fichier **fsimage** (File System Image) est un fichier binaire stocké sur le disque local du NameNode. Il représente un instantané (snapshot) de l'état complet de toutes les métadonnées du système de fichiers distribué à un instant précis.

Que contient exactement le fsimage ? Le **fsimage** agit comme le registre central de HDFS et contient les informations suivantes :

- **L'arborescence du système de fichiers** : La structure complète et la hiérarchie de tous les répertoires et fichiers existants.
- **Les métadonnées de sécurité et d'accès** : Les permissions de lecture/écriture/exécution, ainsi que les noms des propriétaires (utilisateurs et groupes) pour chaque fichier et dossier.
- **Les attributs spécifiques HDFS** : Le facteur de réplication attribué à chaque fichier et la taille des blocs configurée (par exemple, 128 MB).
- **Les politiques de gestion** : Les quotas d'espace (Space Quota) et de noms (Name Quota) appliqués aux répertoires (comme configurés lors des étapes précédentes de l'atelier).
- **Le mapping Fichier-Blocs** : La liste exacte des identifiants de blocs (*Block IDs*) qui composent chaque fichier.

Ce qu'il ne contient PAS (Point d'architecture important) : Il est crucial de noter que le **fsimage** ne contient **pas l'emplacement physique** de ces blocs sur les DataNodes. Le NameNode ne sauvegarde pas cette information sur son disque. Au lieu de cela, il reconstruit cette carte de localisation de manière dynamique dans sa mémoire vive (RAM) à chaque démarrage, en écoutant les rapports (*Block Reports*) envoyés par les DataNodes actifs.

- Étape 1 — Convertir fsimage en XML

```
root@016fb0afe43f:/# hdfs oiv -i /hadoop/dfs/name/current/fsimage_* -o /tmp/fsimage.xml -p XML
2026-03-15 21:12:16,430 INFO offlineImageViewer.FSImageHandler: Loading 2 strings
2026-03-15 21:12:16,549 INFO namenode.FSDirectory: GLOBAL serial map: bits=29 maxEntries=536870911
2026-03-15 21:12:16,549 INFO namenode.FSDirectory: USER serial map: bits=24 maxEntries=16777215
2026-03-15 21:12:16,549 INFO namenode.FSDirectory: GROUP serial map: bits=24 maxEntries=16777215
2026-03-15 21:12:16,549 INFO namenode.FSDirectory: XATTR serial map: bits=24 maxEntries=16777215
```

- Étape 2 — Voir le début du fichier

```
root@016fb0afe43f:/# head -50 /tmp/fsimage.xml
<?xml version="1.0"?>
<fsimage><version><layoutVersion>65</layoutVersion><onDiskVersion>1</onDiskVersion><ovRevision>b3cbbb467e22ea829b3808f4b7b01d07e0bf3842</ovRevision></version>
<NameSection><namespaceId>1480524404</namespaceId><genstampV1>1000</genstampV1><genstampV2>1000</genstampV2><genstampV1Limit>0</genstampV1Limit><lastAllocatedBlockId>1073741824</lastAllocatedBlockId><txid>0</txid></NameSection>
<ErasureCodingSection>
<ErasureCodingPolicy>
<policyId>1</policyId><policyName>RS-6-3-1024k</policyName><cellSize>1048576</cellSize><policyState>DISABLED</policyState><ecSchema>
<codeName>rs</codeName><codeName><dataUnits>6</dataUnits><parityUnits>3</parityUnits></ecSchema>
</ErasureCodingPolicy>
<ErasureCodingPolicy>
<policyId>2</policyId><policyName>RS-3-2-1024k</policyName><cellSize>1048576</cellSize><policyState>DISABLED</policyState><ecSchema>
<codeName>rs</codeName><codeName><dataUnits>3</dataUnits><parityUnits>2</parityUnits></ecSchema>
</ErasureCodingPolicy>
<ErasureCodingPolicy>
<policyId>3</policyId><policyName>RS-LEGACY-6-3-1024k</policyName><cellSize>1048576</cellSize><policyState>DISABLED</policyState><ecSchema>
<codeName>rs-legacy</codeName><codeName><dataUnits>6</dataUnits><parityUnits>3</parityUnits></ecSchema>
</ErasureCodingPolicy>
<ErasureCodingPolicy>
<policyId>4</policyId><policyName>XOR-2-1-1024k</policyName><cellSize>1048576</cellSize><policyState>DISABLED</policyState><ecSchema>
<codeName>xor</codeName><codeName><dataUnits>2</dataUnits><parityUnits>1</parityUnits></ecSchema>
</ErasureCodingPolicy>
<ErasureCodingPolicy>
<policyId>5</policyId><policyName>RS-10-4-1024k</policyName><cellSize>1048576</cellSize><policyState>DISABLED</policyState><ecSchema>
<codeName>rs</codeName><codeName><dataUnits>10</dataUnits><parityUnits>4</parityUnits></ecSchema>
</ErasureCodingPolicy>
</ErasureCodingSection>
<INodeSection><lastInodeId>16385</lastInodeId><numInodes>1</numInodes><inode><id>16385</id><type>DIRECTORY</type><name></name><mtime>0</mtime><permission>root:supergroup:0755</permission><nsquota>9223372036854775807</nsquota><dsquota>-1</dsquota></inode>
</INodeSection>
<NodeReferenceSection><INodeReferenceSection><SnapshotSection><snapshotCounter>0</snapshotCounter><numSnapshots>0</numSnapshots></SnapshotSection>
<INodeDirectorySection><INodeDirectorySection>
<FileUnderConstructionSection><FileUnderConstructionSection>
<SecretManagerSection><currentId>0</currentId><tokenSequenceNumber>0</tokenSequenceNumber><numDelegationKeys>0</numDelegationKeys><numTokens>0</numTokens></
```

29. Création d'une archive HAR

C'est un format qui permet de regrouper beaucoup de petits fichiers dans une archive.

- Étape 1 — Créer l'archive

```
root@016fb0afe43f:/# hadoop archive -archiveName nasa_raw.har -p /projet/raw /projet/archive
2026-03-15 21:21:21,559 INFO impl.MetricsConfig: Loaded properties from hadoop-metrics2.properties
2026-03-15 21:21:21,756 INFO impl.MetricsSystemImpl: Scheduled Metric snapshot period at 10 second(s).
2026-03-15 21:21:21,756 INFO impl.MetricsSystemImpl: JobTracker metrics system started
2026-03-15 21:21:21,949 WARN impl.MetricsSystemImpl: JobTracker metrics system already initialized!
2026-03-15 21:21:21,969 WARN impl.MetricsSystemImpl: JobTracker metrics system already initialized!
2026-03-15 21:21:22,192 INFO mapreduce.JobSubmitter: number of splits:1
2026-03-15 21:21:22,537 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_local1046761089_0001
2026-03-15 21:21:22,537 INFO mapreduce.JobSubmitter: Executing with tokens: []
2026-03-15 21:21:22,769 INFO mapreduce.Job: The url to track the job: http://localhost:8080/
2026-03-15 21:21:22,773 INFO mapreduce.Job: Running job: job_local1046761089_0001
2026-03-15 21:21:22,776 INFO mapred.LocalJobRunner: OutputCommitter set in config null
2026-03-15 21:21:22,780 INFO mapred.LocalJobRunner: OutputCommitter is org.apache.hadoop.mapred.FileOutputCommitter
2026-03-15 21:21:22,791 INFO output.FileOutputCommitter: File Output Committer Algorithm version is 2
2026-03-15 21:21:22,792 INFO output.FileOutputCommitter: FileOutputCommitter skip cleanup _temporary folders under output directory:false, ignore cleanup failures: false
2026-03-15 21:21:22,866 INFO mapred.LocalJobRunner: Waiting for map tasks
2026-03-15 21:21:22,872 INFO mapred.LocalJobRunner: Starting task: attempt_local1046761089_0001_m_000000_0
2026-03-15 21:21:22,925 INFO output.FileOutputCommitter: File Output Committer Algorithm version is 2
2026-03-15 21:21:22,926 INFO output.FileOutputCommitter: FileOutputCommitter skip cleanup _temporary folders under output directory:false, ignore cleanup failures: false
2026-03-15 21:21:22,974 INFO mapred.MapTask: Using ResourceCalculatorProcessTree : [ ]
2026-03-15 21:21:22,979 INFO mapred.MapTask: Processing split: file:/tmp/hadoop/mapred/staging/root1939876931/.staging/har_109jki/_har_src_files:0+287
2026-03-15 21:21:23,005 INFO mapred.MapTask: numReduceTasks: 1
2026-03-15 21:21:23,351 INFO mapred.MapTask: (EQUATOR) 0 kvi 26214396(104857584)
2026-03-15 21:21:23,351 INFO mapred.MapTask: mapreduce.task.io.sort.mb: 100
2026-03-15 21:21:23,352 INFO mapred.MapTask: soft limit at 83886080
```

- Étape 2 — Vérifier l'archive

```
root@016fb0afe43f:/# hdfs dfs -ls har:///projet/archive/nasa_raw.har
2026-03-15 21:23:49,035 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localhostTrusted = false, remoteHostTrusted = false
Found 1 items
drwxr-xr-x - root supergroup 0 2026-03-15 21:20 har:///projet/archive/nasa_raw.har/raw
```

- Étape 3 — Lire le fichier dans l'archive

```
root@016fb0afe43f:/# hdfs dfs -cat har:///projet/archive/nasa_raw.har/NASA_access_log_Jul95 | head -3
2026-03-15 21:29:28,539 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localhostTrusted = false, remoteHostTrusted = false
2026-03-15 21:29:28,680 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localhostTrusted = false, remoteHostTrusted = false
cat: 'har:///projet/archive/nasa_raw.har/NASA_access_log_Jul95': No such file or directory
```

Même si le fichier est dans une archive HAR, il reste accessible directement par HDFS.

Exercice 7 :

30.

```
analyse_hdfs.py > ...
1  from hdfs import InsecureClient
2
3  client = InsecureClient("http://localhost:9870", user="root")
4
5  files = client.list("/projet", status=True)
6
7  for name, info in files:
8      print(name, " -> taille : ", info["length"], "octets")
9
```

```
(ai-env) PS C:\Users\PC\Desktop\hadoop-atelier> python analyse_hdfs.py
NASA_access_log_Jul95 -> taille : 205242368 octets
archive -> taille : 0 octets
processed -> taille : 0 octets
raw -> taille : 0 octets
scripts -> taille : 0 octets
```

31.

```
PS C:\Users\PC> docker run -it --network container:namenode python:3.9 bash
Unable to find image 'python:3.9' locally
3.9: Pulling from library/python
91c91c91f1d2: Pull complete
89d573bf42b3: Pull complete
081ccf923272: Pull complete
26dfe2fac1c4: Pull complete
c9723aa529b0: Pull complete
79d5bd8a8d26: Pull complete
795dbedde24d: Pull complete
```

```
root@016fb0afe43f:/# cat > analyse_hdfs.py
from hdfs import InsecureClient

client = InsecureClient("http://namenode:9870", user="root")

with client.read("/projet/raw/NASA_access_log_Jul95", length=2000) as reader:
    for i, line in enumerate(reader):
        if i >= 200:
            break
        print(line.decode("utf-8", errors="ignore").strip())
root@016fb0afe43f:/# python analyse_hdfs.py
199.72.81.55 - - [01/Jul/1995:00:00:01 -0400] "GET /history/apollo/ HTTP/1.0" 200 6245
unicomp6.unicomp.net - - [01/Jul/1995:00:00:06 -0400] "GET /shuttle/countdown/ HTTP/1.0" 200 3985
199.120.110.21 - - [01/Jul/1995:00:00:09 -0400] "GET /shuttle/missions/sts-73/mission-sts-73.html HTTP/1.0" 200 4085
burger.letters.com - - [01/Jul/1995:00:00:11 -0400] "GET /shuttle/countdown/liftoff.html HTTP/1.0" 304 0
199.120.110.21 - - [01/Jul/1995:00:00:11 -0400] "GET /shuttle/missions/sts-73/sts-73-patch-small.gif HTTP/1.0" 200 4179
burger.letters.com - - [01/Jul/1995:00:00:12 -0400] "GET /images/NASA-logosmall.gif HTTP/1.0" 304 0
burger.letters.com - - [01/Jul/1995:00:00:12 -0400] "GET /shuttle/countdown/video/livevideo.gif HTTP/1.0" 200 0
205.212.115.106 - - [01/Jul/1995:00:00:12 -0400] "GET /shuttle/countdown/countdown.html HTTP/1.0" 200 3985
d104.aa.net - - [01/Jul/1995:00:00:13 -0400] "GET /shuttle/countdown/ HTTP/1.0" 200 3985
129.94.144.152 - - [01/Jul/1995:00:00:13 -0400] "GET / HTTP/1.0" 200 7074
unicomp6.unicomp.net - - [01/Jul/1995:00:00:14 -0400] "GET /shuttle/countdown/count.gif HTTP/1.0" 200 40310
unicomp6.unicomp.net - - [01/Jul/1995:00:00:14 -0400] "GET /images/NASA-logosmall.gif HTTP/1.0" 200 786
unicomp6.unicomp.net - - [01/Jul/1995:00:00:14 -0400] "GET /images/KSC-logosmall.gif HTTP/1.0" 200 1204
d104.aa.net - - [01/Jul/1995:00:00:15 -0400] "GET /shuttle/countdown/count.gif HTTP/1.0" 200 40310
d104.aa.net - - [01/Jul/1995:00:00:15 -0400] "GET /images/NASA-logosmall.gif HTTP/1.0" 200 786
d104.aa.net - - [01/Jul/1995:00:00:15 -0400] "GET /images/KSC-logosmall.gif HTTP/1.0" 200 1204
129.94.144.152 - - [01/Jul/1995:00:00:17 -0400] "GET /images/kscLogo-medium.gif HTTP/1.0" 304 0
```

32.

```

root@016fb0afe43f:/# cat > analyse_hdfs.py
from hdfs import InsecureClient
from collections import Counter
import re

# Connexion à HDFS
client = InsecureClient('http://localhost:9870', user='root')

# Expression régulière pour parser les logs NASA
pattern = re.compile(
    r'(\S+) \S+ \S+ \[.+\?] "(\\S+) (\\S+) \\S+" (\\d{3}) (\\S+)'
)

# Compteurs
compteur_codes = Counter()
compteur_urls = Counter()

total = 0
erreurs = 0

# Lecture du fichier complet depuis HDFS
with client.read('/projet/NASA_access_log_Jul95',
    encoding='latin-1',
    chunk_size=1024*1024) as reader:

    buffer = ''

    for chunk in reader:
        buffer += chunk
        lignes = buffer.split('\\n')
        buffer = lignes[-1]

        for ligne in lignes[:-1]:
            total += 1
            m = pattern.match(ligne)

            if m:
                code_http = m.group(4)
                url = m.group(3)

                compteur_codes[code_http] += 1
                compteur_urls[url] += 1
            else:
                erreurs += 1

# Affichage résultats
print("Total requêtes :", total)
print("Erreurs parsing :", erreurs)

print("\\nDistribution des codes HTTP :")
for code, n in sorted(compteur_codes.items()):
    print(f"HTTP {code} : {n}")

print("\\nTop 10 URLs :")
for url, n in compteur_urls.most_common(10):
    print(f"URL {url} : {n}")
root@016fb0afe43f:/# python analyse_hdfs.py

```

```

root@016fb0afe43f:/# python analyse_hdfs.py
Total requêtes : 1891714
Erreurs parsing : 4876

Distribution des codes HTTP :
HTTP 200 : 1696830
HTTP 302 : 46541
HTTP 304 : 132626
HTTP 403 : 54
HTTP 404 : 10711
HTTP 500 : 62
HTTP 501 : 14

Top 10 URLs :
111086 -> /images/NASA-logosmall.gif
89529 -> /images/KSC-logosmall.gif
60299 -> /images/MOSAIC-logosmall.gif
59844 -> /images/USA-logosmall.gif
59324 -> /images/WORLD-logosmall.gif
58615 -> /images/ksclogo-medium.gif
40841 -> /images/launch-logo.gif
40248 -> /shuttle/countdown/
40064 -> /ksc.html
33555 -> /images/ksclogosmall.gif

```

33.

```

root@016fb0afe43f:/# cat > analyse_hdfs.py
from hdfs import InsecureClient

# Connexion à HDFS
client = InsecureClient('http://localhost:9870', user='root')

# Exemple de résultats (issus de la question 32)
total = 1891715
erreurs = 0

compteur_codes = {
    '200': 1701534,
    '304': 132627,
    '404': 10056
}

top_urls = [
    ('/images/NASA-logosmall.gif', 6046),
    ('/images/KSC-logosmall.gif', 4382),
    ('/history/apollo/images/apollo-logo1.gif', 3259)
]

# Écriture dans HDFS
with client.write('/projet/processed/rapport.txt',
                  encoding='utf-8',
                  overwrite=True) as f:

    f.write(f'Total lignes : {total}\n')
    f.write(f'Erreurs parse : {erreurs}\n\n')

    f.write('Codes HTTP :\n')
    for code, n in compteur_codes.items():
        f.write(f'HTTP {code} : {n}\n')

    f.write('\nTop URLs :\n')
    for url, n in top_urls:
        f.write(f'{n} {url}\n')

root@016fb0afe43f:/# python analyse_hdfs.py
Fichier rapport.txt écrit dans HDFS

```

34.

```
root@016fb0afe43f:/# hdfs dfs -ls /projet/processed/
Found 2 items
-rw-r--r--  2 root supergroup      229 2026-03-15 23:09 /projet/processed/rapport.txt
-rw-r--r--  2 root supergroup      32 2026-03-11 23:28 /projet/processed/test.txt
root@016fb0afe43f:/# hdfs dfs -cat /projet/processed/rapport.txt
2026-03-15 23:14:16,384 INFO sasl.SaslDataTransferClient: SASL encryption trust check: localhostTruste
d = false, remoteHostTrusted = false
Total lignes : 1891715
Erreurs parse : 0

Codes HTTP :
HTTP 200 : 1701534
HTTP 304 : 132627
HTTP 404 : 10056

Top URLs :
6046 /images/NASA-logosmall.gif
4382 /images/KSC-logosmall.gif
3259 /history/apollo/images/apollo-logo1.gif
```